

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
"НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК**

Вольхин Данил Федорович

**МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ
ОРГАНИЗАЦИЯ КООПЕРАТИВНОГО ВОСПРИЯТИЯ СЦЕНЫ В ГРУППЕ
АВТОНОМНЫХ АГЕНТОВ НА ОСНОВЕ ОБМЕНА ВИЗУАЛЬНОЙ
ИНФОРМАЦИЕЙ
COOPERATIVE VISUAL PERCEPTION IN MULTI-AGENT SYSTEMS**

по направлению подготовки 01.04.02 Прикладная математика и информатика
образовательная программа «Исследование и предпринимательство в
искусственном интеллекте»

Научный руководитель
Старший преподаватель, базовая кафедра МТС
_____И.С. Копылов_____

Студент
_____Д.Ф. Вольхин_____

Москва 2026

АННОТАЦИЯ

Работа посвящена проектированию и реализации многоагентной робототехнической платформы AgentsSwarm, обеспечивающей кооперативное восприятие сцены группой мобильных роботов, стандартизованное управление флотом и высокоуровневую оркестрацию задач посредством больших языковых моделей.

Цель работы — создание интегрированного программного комплекса, в котором запрос пользователя на естественном языке транслируется в скоординированное выполнение миссий группой роботов через единый сквозной контур управления.

Задачи: анализ подходов к кооперативному восприятию и координации многороботных систем; разработка микросервисной архитектуры из восьми взаимосвязанных компонентов; реализация LLM-оркестратора на базе OpenAI Agents SDK с маршрутизатором Router, планировщиком, исполнителем PlanRunner и агентами RobotInfo, MapAnalyst, Navigation, SwarmCoordinator и General; переработка трёх MCP-серверов (Mission Control, Mission Dispatch, ros-msp) с переходом на асинхронную модель вызовов; адаптация форков NVIDIA Mission Control и Mission Dispatch под протокол VDA5050; экспериментальная оптимизация VLA-модели SmolVLA для бортового инференса.

Методология основана на принципах облачной робототехники, событийно-ориентированной архитектуры и протокола Model Context Protocol. Эмпирическая база включает симуляцию флота роботов Carter в NVIDIA Isaac Sim (headless-режим, ROS 2 Jazzy, rosbridge WebSocket); развёртывание LLM-сервиса Qwen2.5-Instruct в режиме Data Parallel на двух узлах Tesla V100 (32 ГБ VRAM) через авторский vLLM-сервис; пайплайн дистилляции, прунинга и квантизации модели SmolVLA.

Результаты: реализованы восемь самостоятельных компонентов — Interface (React + FastAPI + Celery, 168 коммитов, срез v0.5.0), Orchestrator (FastAPI + Agents SDK, 61 коммит, срез v0.5.6), vLLM Service (Data Parallel, срез v0.2.9), доработанные форки Mission Control и Mission Dispatch, настроенный ROS 2 workspace, три переработанных MCP-сервера. Контрольный локальный pytest-прогон актуального кода Orchestrator подтвердил 66 из 88 тестов; оставшиеся падения связаны с рассинхронизацией тестовых ожида-

ний после изменения PlanRunner/MapAnalyst и с проверками LLM-клиента. Для модели SmolVLA достигнуто сжатие в 443 раза по числу параметров при сохранении более 90% точности ($MSE +9,1\%$, $R^2 -1,8\%$) и ускорении инференса в 25 раз (450 мс $\rightarrow$ 18 мс, RTX 4090).

ABSTRACT

This thesis presents the design and implementation of AgentsSwarm, a multi-agent robotic platform that enables cooperative scene perception among a group of mobile robots, standardised fleet management, and high-level task orchestration driven by large language models.

The objective is to build an integrated software system in which a natural-language user request is translated into coordinated multi-robot mission execution through a unified end-to-end control pipeline.

Research tasks: analysis of cooperative perception and multi-robot coordination approaches; design of a microservice architecture comprising eight interconnected components; development of an LLM orchestrator based on the OpenAI Agents SDK with Router, a planner, PlanRunner, and the RobotInfo, MapAnalyst, Navigation, SwarmCoordinator, and General agents; rework of three MCP servers (Mission Control, Mission Dispatch, ros-msp) with a migration to asynchronous tool calls; adaptation of NVIDIA Mission Control and Mission Dispatch forks to the VDA5050 protocol; and experimental optimisation of the SmolVLA vision-language-action model for on-board inference.

The methodology is grounded in cloud-robotics principles, event-driven architecture, and the Model Context Protocol. The empirical base comprises simulation of a Carter robot fleet in NVIDIA Isaac Sim (headless mode, ROS 2 Jazzy, rosbridge WebSocket); deployment of a Qwen2.5-Instruct LLM service in Data Parallel mode across two Tesla V100 nodes (32 GB VRAM each) via a custom-built vLLM service; and a knowledge-distillation, pruning, and quantisation pipeline for SmolVLA.

Results: eight independent components were implemented — Interface (React + FastAPI + Celery, 168 commits, v0.5.0 development snapshot), Orchestrator (FastAPI + Agents SDK, 61 commits, v0.5.6 development snapshot), vLLM Service (Data Parallel, v0.2.9 development snapshot), reworked Mission Control and Mission Dispatch forks, a configured ROS 2 workspace, and three redesigned MCP servers. A local pytest control run of the current Orchestrator code passed 66 of 88 tests; the remaining failures are related to outdated test expectations after PlanRunner/MapAnalyst changes and LLM-client checks. The SmolVLA model was compressed 443-fold in parameter count while retaining

over 90% accuracy (MSE +9.1%, R^2 -1.8%) with a $25\times$ inference speed-up (450 ms $\rightarrow$ 18 ms on RTX 4090).

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	9
1 Анализ предметной области и обзор существующих решений	12
1.1 Кооперативное визуальное восприятие в многоагентных системах	12
1.1.1 Постановка задачи и фундаментальный компромисс	12
1.1.2 Ключевые алгоритмические подходы	12
1.2 Совместное картографирование и локализация	13
1.3 Координация флота и стандарты интероперабельности	14
1.3.1 VDA5050 как промышленный стандарт	14
1.3.2 OpenRMF и архитектурные аналоги	14
1.3.3 Behavior Trees как исполнимый формат миссий	14
1.3.4 Облачная и туманная робототехника	15
1.4 Большие языковые модели в робототехнике	15
1.4.1 Смена парадигмы: от диалоговой модели к агенту планирования	15
1.4.2 Парадигма ReAct и вызов инструментов	15
1.4.3 Безопасность и формальные ограничения LLM-планирования	16
1.4.4 LLM для координации роя	16
1.5 Foundation Models и Vision-Language-Action модели	16
1.6 Симуляционные среды и цифровые двойники	17
1.7 Выводы и результаты по главе 1	17
2 Проектирование архитектуры системы AgentsSwarm	19
2.1 Требования к системе	19
2.2 Общая микросервисная архитектура	20
2.3 Протокол взаимодействия агентов: Model Context Protocol	21
2.4 Протокол управления флотом: VDA5050	23

2.5	Агентная архитектура оркестратора	25
2.6	Событийно-ориентированная потоковая модель	26
2.7	Инфраструктура развёртывания	27
2.8	Выводы и результаты по главе 2	28
3	Реализация компонентов системы	29
3.1	Симуляционная среда: NVIDIA Isaac Sim и ROS 2 Workspace .	29
3.2	Mission Control: форк NVIDIA и авторские доработки	31
3.3	Mission Dispatch: форк NVIDIA и авторские доработки	31
3.4	MCP-серверы: переработка официальных реализаций	32
3.5	vLLM Service: авторский сервис инференса	33
3.6	Orchestrator: главный интеллектуальный микросервис	34
3.7	Interface: веб-платформа управления	37
3.7.1	Общая архитектура и стек	38
3.7.2	Backend: агенты и обработка задач	39
3.7.3	Потоковая модель: Redis Streams и WebSocket	40
3.7.4	Frontend: страницы интерфейса	41
3.7.5	Демонстрация рабочего воркфлоу	41
3.8	Выводы и результаты по главе 3	42
4	Оптимизация модели SmolVLA для бортового инференса	44
4.1	Постановка задачи и мотивация	44
4.2	Архитектура SmolVLA и исходные характеристики	44
4.3	Пайплайн оптимизации	45
4.4	Результаты экспериментов	48
4.5	Выводы и результаты по главе 4	48
5	Верификация системы	50
5.1	Стратегия тестирования	50
5.2	Тестирование оркестратора	50
5.3	Тестирование Interface	51
5.4	Выводы и результаты по главе 5	51
	ЗАКЛЮЧЕНИЕ	53
	ОПИСАНИЕ ПРИМЕНЕНИЯ ГЕНЕРАТИВНОЙ МОДЕЛИ	55
	БИБЛИОГРАФИЧЕСКИЙ СПИСОК	57
	ПРИЛОЖЕНИЯ	64

А	Глоссарий предметной области	65
Б	Список сокращений	67
В	Технические характеристики инфраструктуры	68
Г	Ключевые фрагменты кода	69
Д	Протоколы экспериментов	71

ВВЕДЕНИЕ

Современная промышленная робототехника переживает качественный переход от использования одиночных роботов-исполнителей к развёртыванию гетерогенных флотов автономных мобильных роботов (AMR) и автоматизированных транспортных средств (AGV). Задачи складской логистики, промышленной инспекции, гибкого производства всё чаще требуют координированного взаимодействия группы роботов, способных воспринимать и интерпретировать общее пространство операций. Одиночный агент принципиально ограничен угловым полем зрения, дальностью сенсоров и локальными вычислительными ресурсами; группа же агентов, обменивающихся перцептивной информацией, способна совместно формировать наблюдение сцены, недоступное ни одному из них в отдельности.

Вместе с тем координация флота остаётся нетривиальной инженерной задачей. Существующие fleet management системы — в том числе соответствующие стандарту VDA5050 — предоставляют надёжный низкоуровневый контур диспетчеризации миссий, однако не обеспечивают высокоуровневого семантического планирования и не предоставляют пользователю интерфейс на естественном языке. Академические прототипы кооперативного восприятия (V2VNet, Where2comm, CoBEVT) достигают высоких показателей точности на симулированных датасетах, однако не интегрированы с промышленными стандартами координации флота.

Появление мощных больших языковых моделей (LLM) открывает возможность транслировать пользовательский запрос на естественном языке напрямую в координированное выполнение многороботных миссий. Парадигмы ReAct и вызова инструментов превращают языковую модель из диалогового интерфейса в рассуждающего агента, способного обращаться к внешним сервисам, накапливать наблюдения и корректировать план действий.

Объект исследования — многоагентная робототехническая система с кооперативным восприятием и централизованным fleet management.

Предмет исследования — методы организации взаимодействия, координации и LLM-планирования в группе автономных агентов.

Методы исследования: системный анализ, микросервисное проекти-

рование, симуляционный эксперимент, дистилляция нейронных сетей.

Цель работы — создание интегрированного программного комплекса AgentsSwarm, в котором запрос пользователя на естественном языке транслируется в скоординированное выполнение миссий группой роботов через единый сквозной контур управления.

Для достижения цели решены следующие **задачи**:

1. Анализ подходов к кооперативному визуальному восприятию, совместному картографированию, координации флота и применению LLM в робототехнике.
2. Проектирование микросервисной архитектуры из восьми взаимосвязанных компонентов.
3. Реализация LLM-оркестратора на базе OpenAI Agents SDK со специализированными агентами и пошаговым исполнителем PlanRunner.
4. Переработка трёх MCP-серверов с переходом на асинхронную модель вызовов.
5. Адаптация форков NVIDIA Mission Control и Mission Dispatch под протокол VDA5050.
6. Настройка симуляционной среды NVIDIA Isaac Sim с группой роботов Carter.
7. Развёртывание vLLM-сервиса в режиме Data Parallel на кластере из двух узлов Tesla V100.
8. Экспериментальная оптимизация VLA-модели SmolVLA для бортового инференса.

Основные результаты. Реализованы восемь самостоятельных компонентов: Interface (срез v0.5.0, 168 коммитов), Orchestrator (срез v0.5.6, 61 коммит), vLLM Service (срез v0.2.9), доработанные форки Mission Control и Mission Dispatch, настроенный ROS 2 workspace, три переработанных MCP-сервера. Контрольный локальный прогон актуального pytest-набора Orchestrator дал 66 пройденных тестов из 88 и выявил необходимость актуализации части тестовых ожиданий. Для SmolVLA достигнуто сжатие в 443 раза и ускорение инференса в 25 раз при сохранении более 90% точности.

Структура работы. Диссертация состоит из введения, пяти глав, заключения, библиографического списка из 65 источников и пяти приложе-

ний. Глава 1 содержит анализ предметной области и обзор существующих решений. Глава 2 описывает проектирование архитектуры системы. Глава 3 посвящена реализации компонентов. Глава 4 представляет оптимизацию SmolVLA. Глава 5 описывает верификацию системы автоматизированными тестами.

ГЛАВА 1. Анализ предметной области и обзор существующих решений

1.1. Кооперативное визуальное восприятие в многоагентных системах

1.1.1. Постановка задачи и фундаментальный компромисс

Задача кооперативного восприятия формулируется следующим образом: группа агентов, каждый из которых оснащён собственными датчиками (камера, лидар, IMU), должна совместно построить более полное и устойчивое представление об окружающей среде, чем любой агент мог бы получить в одиночку. Ключевым практическим ограничением является *компромисс между качеством восприятия и стоимостью коммуникации*: передача сырых данных с высокой частотой быстро исчерпывает полосу пропускания, тогда как чрезмерное сжатие ведёт к потере перцептивно важной информации.

Обзорные работы систематизируют подходы к кооперативному восприятию по трём уровням обмена: ранний (сырые данные), поздний (готовые детекции) и промежуточный (признаки из скрытых слоёв) [1, 2]. Промежуточный уровень в настоящее время рассматривается как наиболее перспективный, поскольку позволяет существенно снизить объём передаваемых данных при незначительных потерях качества. Реальная ценность cooperative perception возникает не просто от «обмена данными», а от обмена компактными, согласованными и выборочно передаваемыми признаками [2].

1.1.2. Ключевые алгоритмические подходы

V2VNet [3] стал одной из первых работ, показавших практическую применимость промежуточного слияния: автомобили обмениваются сжатыми картами активаций, что позволяет обнаруживать объекты за препятствиями. Система достигает 30% прироста в mAP по сравнению с одиночным восприятием при ограниченной полосе пропускания.

When2com [4] ввёл принципиально новый вопрос: не только *чем* делиться, но и *когда* стоит коммуницировать. Предложенный механизм handshake позволяет агенту запрашивать информацию только тогда, когда

она действительно повышает качество восприятия, формируя динамические группы через граф коммуникации.

Where2comm [5] развивает идею пространственной выборки: агенты передают только перцептивно важные, пространственно разреженные фрагменты карты признаков, используя *spatial confidence maps*. Система демонстрирует до 1000-кратного сжатия объёма передаваемых данных при незначительном снижении качества.

V2X-ViT [6] переносит трансформерную архитектуру на задачу V2X-восприятия, вводя чередующиеся слои гетерогенного *self-attention* между агентами и *multi-scale window self-attention* внутри каждого агента.

OPV2V [7] и **CoBEVT** [8] представляют первый крупный открытый бенчмарк для V2V-восприятия и первый фреймворк для кооперативной генерации Bird's Eye View карт соответственно. Датасет **CoPeD** [9] — первый гетерогенный реальный датасет для многороботного кооперативного восприятия с воздушными и наземными роботами — фиксирует разрыв между автомобильной кооперативной перцепцией и задачами robotics.

1.2. Совместное картографирование и локализация

Параллельным направлением к cooperative perception является **Collaborative SLAM (C-SLAM)** — совместное построение карты и локализация несколькими роботами. Обзор [10] систематизирует свыше 100 работ и выделяет три фундаментальные проблемы: робастность (устойчивость к ошибкам ассоциации данных), управление коммуникацией и вычислительная масштабируемость при росте числа агентов.

Swarm-SLAM [11] представляет открытую децентрализованную C-SLAM систему, поддерживающую лидарные, стерео-, RGB-D и инерциальные сенсоры. Ключевое нововведение — техника приоритизации межроботных замыканий петель, позволяющая сократить объём передаваемых данных при ускорении сходимости. Тренд в направлении C-SLAM — движение от централизованных схем к разреженным децентрализованным, что согласуется с логикой масштабирования реальных многороботных флотов.

Для AgentsSwarm эти работы образуют теоретический мост между «обменом визуальной информацией» и «совместным выполнением миссий на общей карте»: система использует *occupancy map* и *waypoint graph* как общее

пространственное представление, доступное всем компонентам планирования.

1.3. Координация флота и стандарты интероперабельности

1.3.1. VDA5050 как промышленный стандарт

Стандарт **VDA5050** [12], разработанный VDA и VDMA, определяет открытый протокол коммуникации между флотом мобильных роботов (AGV/AMR) и центральной системой fleet control через MQTT-брокер и JSON-сообщения. Стандарт явно нацелен на решение проблемы *интероперабельности*: роботы разных производителей должны взаимодействовать с единым fleet manager без уникальных point-to-point интеграций.

Работа [13] рассматривает VDA5050 с промышленной перспективы: авторы из Robert Bosch GmbH анализируют задачи multi-agent decision making для реальных intralogistics-сценариев, где AMR работают рядом с людьми, legacy AGV и разнородным оборудованием. Для промышленного развёртывания уже недостаточно «уметь ездить»: нужен interoperable decision stack с поддержкой VDA5050 как единого языка взаимодействия.

1.3.2. OpenRMF и архитектурные аналоги

Open RMF [14] реализует централизованные функции: task queuing, conflict-free scheduling и fleet adapters для совместимости с разными роботами. Core-пакеты OpenRMF предоставляют не алгоритмы навигации, а middleware-логику — то же разделение ответственности, что реализовано в AgentsSwarm между Mission Control (планирование и граф карты) и Mission Dispatch (очередь и доставка миссий).

1.3.3. Behavior Trees как исполнимый формат миссий

Behavior Trees (BT) [15] стали доминирующим подходом к формализации миссионной логики в современной робототехнике: по сравнению с классическими FSM, BT лучше масштабируются при усложнении поведения и обеспечивают более явное разделение логики условий и действий. Mission Control NVIDIA использует BT как внутренний исполнимый формат для разложения высокоуровневых задач на последовательности действий роботов.

1.3.4. Облачная и туманная робототехника

FogROS2 [16] демонстрирует, что вынос вычислительно тяжёлых алгоритмов (SLAM, планирование захватов) в облако снижает задержку SLAM на 50% и ускоряет планирование захватов с 14 с до 1,2 с. **Robofleet** [17] решает задачу эффективной коммуникации в флоте с дедупликацией трафика и адаптивным обратным давлением. Литература последовательно указывает на практичность архитектур, где низкоуровневое управление остаётся в робототехническом стеке (ROS 2, VDA5050 клиент), а облачный слой отвечает за планирование и семантическое рассуждение. Именно эту стратегию реализует **AgentsSwarm**.

1.4. Большие языковые модели в робототехнике

1.4.1. Смена парадигмы: от диалоговой модели к агенту планирования

Применение LLM в робототехнике прошло несколько этапов. Ранние работы использовали языковые модели как интерфейс понимания команд. Затем акцент сместился к декомпозиции задач и выбору действий на основе контекста. Обзоры [18, 19] классифицируют применение LLM по четырём слоям: коммуникация с человеком, перцептивная семантическая интерпретация, планирование задач и генерация действий. Для многоагентных систем выделяется отдельный класс задач: высокоуровневая координация, распределение задач и надзор с участием человека [19].

1.4.2. Парадигма ReAct и вызов инструментов

ReAct [20] стал методологической основой для агентных систем нового поколения: LLM чередует генерацию рассуждений (*reasoning traces*) и действий (*actions*), что позволяет корректировать план на основе наблюдаемых результатов. В отличие от одношагового *prompting*, **ReAct** создаёт замкнутый цикл *reasoning* → *action* → *observation* → *reasoning*.

SayCan [21] решает проблему «заземления» языкового плана в физические ограничения среды: LLM генерирует вероятности возможных действий, а модель аффордансов взвешивает их реализуемость (84% точности планирования, 74% успеха выполнения). **ProgPrompt** [22] вводит программноподобную структуру промптов, что существенно повышает воспроизводимость генерируемых планов.

Архитектура оркестратора AgentsSwarm следует той же логике: LLM работает как высокоуровневый диспетчер и планировщик поверх инструментов (MCP-серверы) и mission APIs, не находясь в servo-loop робота.

1.4.3. Безопасность и формальные ограничения LLM-планирования

SELP [23] предлагает три техники для генерации безопасных планов: голосование по эквивалентности, constrained decoding через LTL-формулы и доменное дообучение. Система показывает +10,8% к safety rate и +19,8% к эффективности для навигации БПЛА. Это направление актуально для AgentsSwarm: текущая система разграничивает LLM-слой и mission-контур, однако формальная верификация LLM-выходов остаётся открытым вопросом.

1.4.4. LLM для координации роя

Swarm-GPT [24] исследует применение LLM для управления роем БПЛА: модель генерирует траектории, а алгоритм безопасного планирования фильтрует коллизии (100% безопасных траекторий после фильтрации против 21,65% напрямую от LLM). Ключевой принцип: *LLM как генератор идей, классический алгоритм как гарант безопасности*.

1.5. Foundation Models и Vision-Language-Action модели

RT-2 [25] продемонстрировал, что совместное обучение на данных роботов и интернет-данных позволяет VLA-модели переносить семантические знания в реальное управление роботом. **VoxPoser** [26] показал комплементарный подход: LLM генерирует код для составления 3D value maps, по которым планировщик синтезирует траектории манипулятора в zero-shot режиме. **OpenVLA** [27] — открытая модель на 7B параметров, поддерживающая fine-tuning через LoRA. **Open X-Embodiment** [28] — датасет из более чем 1M реальных траекторий от 22 типов роботов — стал одним из ключевых ресурсов для обобщённых VLA-моделей. π_0 [29] представляет следующий уровень — универсальный VLA на основе flow matching.

Параллельно с масштабированием идёт компактификация VLA для ресурсно ограниченных платформ. **SmolVLA** [30] (450M параметров) обучается на одном GPU и сохраняет производительность при значительно меньших требованиях. **TinyVLA** [31] с диффузионным декодером превос-

ходит OpenVLA при задержке инференса в 20 раз меньше. В контексте AgentsSwarm экспериментальный модуль SmolVLA Tools реализовал пайплайн оптимизации SmolVLA с результатами, описанными в главе 4.

1.6. Симуляционные среды и цифровые двойники

NVIDIA Isaac Sim [32] — фотореалистичная физически правдоподобная среда симуляции, построенная на Omniverse. Официальный tutorial по multi-robot navigation демонстрирует одновременную навигацию нескольких роботов с ROS 2 namespaces — это практически совпадает с логикой AgentsSwarm, где одна сцена обслуживает несколько роботов Carter. **Orbit (Isaac Lab)** [33] позиционирует Isaac Sim как унифицированный фреймворк для роботообучения. **Pegasus Simulator** [34] демонстрирует расширяемость Isaac Sim для специфических платформ (БПЛА с PX4).

Обзор по AI-driven цифровым двойникам [35] показывает, что основная сложность лежит не в симуляции как таковой, а в интероперабельности моделей и sim-to-real переносе. Для AgentsSwarm это задаёт границу применимости: система закрывает симуляционный и оркестрационный контур, но перенос на физический флот требует отдельного исследовательского этапа.

vLLM / PagedAttention [36] решает проблему эффективного использования GPU-памяти при обслуживании LLM: алгоритм PagedAttention, вдохновлённый виртуальной памятью ОС, увеличивает пропускную способность в 2–4 раза. **Qwen2.5** [37] — семейство открытых instruction-following моделей, обученных на 18 трлн токенов. Выбор Qwen-Instruct как основной модели оркестратора задаёт баланс между качеством вызова инструментов и доступностью для самостоятельного развёртывания.

1.7. Выводы и результаты по главе 1

На основе проведённого анализа можно выделить несколько классов существующих систем и сопоставить с ними AgentsSwarm.

Академические прототипы кооперативного восприятия (V2VNet, Where2comm, CoBEVT) сосредоточены на алгоритмической эффективности feature fusion. Они не решают задачу интеграции восприятия с fleet management и не имеют исполнимого миссионного контура. AgentsSwarm дополняет этот класс: вместо нового алгоритма fusion предлагается архитекту-

ра, в которой кооперативное восприятие встроено в полный цикл управления флотом.

Промышленные fleet management системы (OpenRMF, VDA5050-совместимые стеки) решают задачи координации и интероперабельности, но не интегрируют семантическое LLM-планирование. AgentsSwarm добавляет этот слой через оркестратор с маршрутизатором, планировщиком и специализированными агентами исполнения.

LLM-robotics прототипы (SayCan, Swarm-GPT, RT-2) демонстрируют применение языковых и мультимодальных моделей, но либо работают с одиноким роботом, либо не интегрированы с промышленными стандартами координации флота. AgentsSwarm соединяет LLM-слой с VDA5050-контуром.

Положение AgentsSwarm между академическими работами по collaborative perception, промышленными multi-robot middleware и исследованиями LLM-driven robotics определяет вклад работы: система не предлагает новый state-of-the-art алгоритм feature fusion, но демонстрирует воспроизводимую интеграцию этих направлений в единый исполнимый контур.

Открытыми вопросами остаются: формальные гарантии LLM-слоя (hallucination, constraint violations), sim-to-real перенос и бортовая автономность — направления, которые система AgentsSwarm обозначает через модуль SmolVLA Tools и архитектурные расширения, описанные в следующих главах.

ГЛАВА 2. Проектирование архитектуры системы AgentsSwarm

2.1. Требования к системе

Проектирование системы AgentsSwarm началось с формулировки функциональных и нефункциональных требований, определивших архитектурные решения на всех уровнях.

Функциональные требования:

1. Приём пользовательского запроса на естественном языке через веб-интерфейс.
2. Семантическая классификация запроса и выбор специализированного агента-исполнителя.
3. Высокоуровневое планирование миссии с декомпозицией на шаги и назначением целевых роботов.
4. Трансляция плана в VDA5050-совместимые команды через Mission Control и Mission Dispatch.
5. Отображение статуса выполнения миссии в реальном времени (streaming).
6. Поддержка параллельных пользовательских сессий с фоновой обработкой задач.
7. Хранение истории диалогов и персональной памяти пользователя.

Нефункциональные требования:

- *Воспроизводимость*: все компоненты упакованы в Docker-контейнеры с фиксированными версиями зависимостей.
- *Интероперабельность*: использование открытых стандартов (VDA5050, MCP, ROS 2, OpenAI-compatible API).
- *Масштабируемость*: горизонтальное масштабирование агентов через Celery-воркеры.
- *Наблюдаемость*: структурированные события в Redis Stream, трассировка агентного маршрута в UI.

Ограничения: система развёртывается на трёх облачных машинах

(Selectel, MTS Cloud), что определяет распределение компонентов по узлам и требования к сетевому взаимодействию.

2.2. Общая микросервисная архитектура

Система декомпозирована на восемь самостоятельных компонентов, взаимодействующих через REST API, WebSocket, MQTT и Model Context Protocol [49].

1. **Interface** — пользовательский веб-портал (React + FastAPI + Celery + RabbitMQ + Redis Streams + PostgreSQL + MinIO) [61, 62, 54, 57, 56, 55, 58, 60, 59]. Принимает запросы, маршрутизирует к агентам, стримит ответы через WebSocket.
2. **Orchestrator** — главный интеллектуальный сервис (FastAPI + OpenAI Agents SDK). Содержит маршрутизатор, планировщик, исполнитель шагов и специализированных агентов, взаимодействующих с роботическим контуром через MCP-серверы.
3. **vLLM Service** — сервис инференса LLM в режиме Data Parallel ($2 \times$ Tesla V100). Предоставляет OpenAI-compatible API [52, 53].
4. **Mission Control** — форк NVIDIA, реализующий VDA5050-совместимый fleet manager с Behavior Tree планировщиком и cuOpt-оптимизацией [45, 47].
5. **Mission Dispatch** — форк NVIDIA, реализующий очередь миссий и VDA5050-обмен через MQTT [46].
6. **Isaac Sim** — среда симуляции NVIDIA с роботами Carter в headless-режиме, интегрированная с ROS 2 Jazzy [32, 41].
7. **ROS 2 Workspace** — форк с дополнительными пакетами навигации, VDA5050 клиентом, rosbridge WebSocket [39, 40, 42, 43, 44].
8. **SmolVLA Tools** — экспериментальный модуль оптимизации VLA-модели [63, 64, 65].

Слои системы: *воспринимающий* (Isaac Sim, ROS 2), *планирующий* (Orchestrator, vLLM, MCP-серверы) и *исполняющий* (Mission Control, Mission Dispatch, VDA5050 клиент робота).

Общая схема взаимодействия компонентов приведена на рис. 2.1.




Рис. 2.1. Общая схема взаимодействия компонентов системы AgentsSwarm

2.3. Протокол взаимодействия агентов: Model Context Protocol

Model Context Protocol (MCP) [49] — открытый стандарт для взаимодействия LLM-агентов с внешними инструментами и данными. Протокол определяет архитектуру клиент-сервер, где MCP-клиент (агент) вызывает tools, resources и prompts, предоставляемые MCP-сервером. Транспортный слой поддерживает два режима: SSE (Server-Sent Events) для HTTP-развёртывания и stdio для локальных процессов.

В системе AgentsSwarm реализованы три MCP-сервера с чёткими зонами ответственности:

- `mission-control-mcp` — инструменты для работы с картой, waypoint-графом и статусами роботов (Mission Control API);
- `mission-dispatch-mcp` — инструменты для создания, управления и мониторинга миссий (Mission Dispatch API);
- `ros-msp` — инструменты для публикации в ROS 2 топики и чтения из них через rosbridge WebSocket [50].

MCP обеспечивает строгое разделение ответственности: агентный слой

не зависит от конкретной реализации роботического контура и взаимодействует с ним исключительно через стандартизованный tool-интерфейс. Это позволяет заменять или расширять роботический контур без модификации кода оркестратора.

Зоны ответственности MCP-серверов показаны на рис. 2.2.




Рис. 2.2. Три MCP-сервера системы AgentsSwarm и их зоны ответственности

2.4. Протокол управления флотом: VDA5050

Стандарт VDA5050 [12] определяет JSON-структуры сообщений, передаваемых через MQTT-брокер:

- `order` — задание для робота (последовательность узлов графа и рёбер с действиями);
- `state` — текущее состояние робота (позиция, статус, ошибки, уровень заряда);
- `connection` — статус подключения робота к `fleet manager`.

Маршрут команды в `AgentsSwarm`:

Orchestrator → MCP-сервер → Mission Dispatch API → MQTT → VDA5050 клиент → Isaac Sim

Mission Control принимает высокоуровневую задачу, строит Behavior Tree, запрашивает оптимальный маршрут у `cuOpt` и формирует VDA5050 `order` для Mission Dispatch. Mission Dispatch публикует `order` в MQTT-топик, VDA5050 клиент робота в Isaac Sim подписан на этот топик и исполняет команду.

Маршрут команды от пользовательского запроса до роботического контура показан на рис. 2.3.




Рис. 2.3. Маршрут команды: Orchestrator → MCP → Mission Dispatch → VDA5050 → робот

2.5. Агентная архитектура оркестратора

Агентная архитектура оркестратора построена по иерархическому принципу: входящий запрос обрабатывается Router Agent, классифицирующим его по восьми категориям, после чего планировщик формирует последовательность исполняемых шагов.

Router Agent классифицирует запросы по категориям: *general* (общие вопросы), *robot_info* (статусы роботов и диагностика), *navigation* (задачи навигации), *charging* (управление зарядкой), *patrol* (патрульные маршруты), *inspection* (инспекция объектов), *fleet_ops* (операции с флотом), *swarm_coord* (координация нескольких роботов). Классификация выполняется через LLM с детерминированными правилами приоритетов.

Planner и PlanRunner реализуют двухфазный алгоритм: на первой фазе строится план в виде последовательности именованных шагов с указанием `target_robots` и зависимостей; на второй — шаги последовательно исполняются через агентов RobotInfo, MapAnalyst, Navigation, SwarmCoordinator и General либо через эвристический fallback в тестовом режиме.

MapAnalyst получает PNG-снимок карты от Mission Control, накладывает позиции роботов и передаёт изображение в vision-LLM для пространственного анализа сцены.

Категории Charging, Patrol, Inspection и FleetOps присутствуют в конфигурации маршрутизатора как расширяемые handoff-направления; в текущем исполняемом контуре PlanRunner основной набор шагов сводится к RobotInfo, MapAnalyst, Navigation, SwarmCoordinator и General.

Иерархия планирования и handoff-направлений приведена на рис. 2.4.




Рис. 2.4. Планировщик, исполнитель шагов и специализированные агенты оркестратора

2.6. Событийно-ориентированная потоковая модель

Асинхронная потоковая модель Interface построена на Redis Stream как шине событий. Агент-воркер публикует события в поток `chat:{thread_id}:stream` командой `XADD`; WebSocket-слой читает поток командой `XREAD` с блокирующим ожиданием и проталкивает события клиенту.

Жизненный цикл задачи: *pending* → *running* (первый чанк) → *completed* или *error*. Типы событий: `stream_chunk`, `agent_reply`, `routing_event`, `tool_event`, `error`.

Параллельный канал — REST-взаимодействие с оркестратором: `SwarmOrchestratorAgent` создаёт задачу через `POST /task`, затем инкрементально опрашивает `GET /task/{id}/events` и транслирует события в Redis Stream Interface, обеспечивая сквозную прозрачность агентного маршрута для пользователя.

Жизненный цикл задачи и потоковая модель событий показаны на рис. 2.5.




Рис. 2.5. Жизненный цикл задачи (pending → completed) и потоковая модель событий Redis Streams

2.7. Инфраструктура развёртывания

Три машины разной конфигурации обслуживают различные подсистемы системы AgentsSwarm (Табл. 2.1).

Таблица 2.1. Технические характеристики вычислительной инфраструктуры

Машина	Провайдер	Конфигурация	Назначение
Симуляция	Selectel	4 vCPU, 16 ГБ RAM, RTX 4090 (24 ГБ VRAM), Ubuntu 24.04	Isaac Sim, ROS 2, Mission Control, Mission Dispatch Interface,
Микросервисы	Selectel	4 vCPU, 8 ГБ RAM, 128 ГБ SSD, Ubuntu 24.04	Orchestrator, Redis, RabbitMQ, MinIO, PostgreSQL
LLM-кластер	MTS Cloud	2 узла × Tesla V100-PCIE 32 ГБ VRAM, Ubuntu 24.04	vLLM Data Parallel (Qwen2.5-Instruct)

Межсервисное взаимодействие: HTTP/REST (оркестратор ↔ MCP, Interface ↔ оркестратор), WebSocket (стриминг событий), MQTT (VDA5050), RPC gRPC (vLLM Data Parallel, порт 13345).

2.8. Выводы и результаты по главе 2

Спроектированная архитектура AgentsSwarm обеспечивает чёткое разделение ответственности между компонентами: пользовательский слой (Interface) изолирован от роботического контура (Mission Control/Dispatch/Isaac Sim) через двухступенчатый агентный барьер (Interface-агенты → Orchestrator-агенты → MCP-серверы).

Принципиальной новизной по сравнению с рассмотренными аналогами является интеграция LLM-слоя с промышленным VDA5050-контуром через стандартизованный MCP-протокол. OpenRMF [14] и аналогичные fleet management системы требуют формального задания задачи через API; AgentsSwarm принимает произвольный запрос на естественном языке и транслирует его в исполнимую последовательность VDA5050-команд. Событийно-ориентированная потоковая модель на Redis Streams обеспечивает наблюдаемость сквозного контура выполнения задачи для пользователя в реальном времени.

ГЛАВА 3. Реализация компонентов системы

3.1. Симуляционная среда: NVIDIA Isaac Sim и ROS 2 Workspace

Симуляционная среда построена на базе NVIDIA Isaac Sim 4.5 в headless-режиме с Web Viewer для удалённого наблюдения [32, 41]. Сцена Carter Warehouse содержит несколько роботов Carter с уникальными ROS 2-пространствами имён (namespaces), что позволяет независимо управлять каждым роботом через единый ROS 2 DDS-мост.

Запуск осуществляется через Docker Compose стек: контейнер Isaac Sim монтирует GPU, обеспечивает доступ к драйверам CUDA и публикует Web Viewer на порту 8211. Конфигурация Action Graph задаёт параметры синтетической камеры, публикует RGB- и depth-изображения в ROS 2-топики и запускает `isaac_ros_mission_client` — официальный пакет NVIDIA, реализующий VDA5050 клиент для флота роботов [40].

ROS 2 Jazzy workspace собирается из форка `isaac_ros_common`, дополненного пакетами для отображения occupancy map, публикации costmap и rosbridge-сервером [39, 42, 43]. Rosbridge WebSocket (порт 9090) обеспечивает доступ к ROS 2-топикам для MCP-сервера без необходимости установки полного стека ROS 2 на машине оркестратора [44].

Occupancy map генерируется из ортогонального вида сцены Isaac Sim, сохраняется в формате PNG и обновляется в Mission Control через маршрут API `/map/update_robot`. На основе карты Mission Control строит waypoint graph — ориентированный граф навигационных узлов, по которому cuOpt рассчитывает оптимальные маршруты.

Интеграция Isaac Sim, ROS 2 и VDA5050 показана на рис. 3.1; пример waypoint graph сцены Carter Warehouse приведён на рис. 3.2.




Рис. 3.1. Схема интеграции Isaac Sim, ROS 2 и VDA5050 в симуляционном контуре




Рис. 3.2. Occupancy map и waypoint graph сцены Carter Warehouse

3.2. Mission Control: форк NVIDIA и авторские доработки

Официальный репозиторий NVIDIA Mission Control реализует централизованный fleet manager для VDA5050-совместимых роботов с Behavior Tree планировщиком и поддержкой cuOpt для оптимизации маршрутов [45, 47]. При развёртывании оригинального кода были выявлены критические ошибки.

Проблема 1: несоответствие маршрута обновления карты. Оригинальный код вызывал `/push_map`, тогда как Mission Control API использует `/map/update_robot` и `/map/metadata`. Исправление потребовало анализа HTTP-трафика между компонентами и корректировки маршрутизации внутри Mission Control.

Проблема 2: устаревший синтаксис Pydantic v1. Модуль `waypoint_selection_ui` использовал декораторы-валидаторы, несовместимые с Pydantic v2. Исправление состояло в замене на актуальный синтаксис `@field_validator`.

Стабилизация Docker-стека включала корректировку порядка запуска зависимых сервисов (cuOpt, Mosquitto, PostgreSQL) и проверку health-check проб для корректной инициализации. После всех исправлений Mission Control успешно принимает задания от оркестратора, строит Behavior Tree и публикует VDA5050 order в Mosquitto.

3.3. Mission Dispatch: форк NVIDIA и авторские доработки

Mission Dispatch реализует очередь миссий и двустороннее VDA5050-взаимодействие между fleet manager и роботами [46]. В оригинальном коде обнаружена проблема с устаревшим маршрутом в пакете `packages/controllers/server`: запросы возвращали 404, нарушая сквозное взаимодействие.

Дополнительно выявлена некорректная конфигурация MQTT-хоста: Mission Dispatch использовал жёстко заданный `localhost` вместо имени сервиса Docker Compose (`mosquitto`), что препятствовало работе в контейнеризованном окружении. После исправления двух ошибок проведена сквозная верификация цепочки:

Isaac Sim → VDA5050 клиент → Mosquitto → Mission Dispatch → Mission Control → Behavior Tree → VDA5050 order → Isaac Sim

3.4. MCP-серверы: переработка официальных реализаций

Три MCP-сервера обеспечивают агентам оркестратора доступ к роботическому контуру через стандартизованный интерфейс инструментов [49, 51]. Исходные реализации MCP-серверов NVIDIA представляли прототипы с нереализованными служебными маршрутами и синхронной моделью вызовов.

Переход на асинхронную модель. Все инструменты переписаны на `async def` с `httpx.AsyncClient` для HTTP и `websockets` для `rosbridge`-соединений. Это обеспечивает корректную работу с `event loop` без блокировки при параллельных вызовах агентов.

mission-control-mcp предоставляет инструменты верхнего уровня Mission Control. Для миссий зарегистрированы обработчики навигации, зарядки и `undock`; основной навигационный вызов в коде имеет имя `submit_navigation_mission`. Для карт используются `get_map_info`, `list_available_maps`, `select_map`, `deploy_map_to_robot` и `visualize_route`. Отдельно реализованы проверка соединения, операции с `detected objects`, `apriltags`, `objectives` и `pick-and-place`. Нереализованные обработчики заменены рабочими служебными маршрутами, необходимыми для корректной инициализации Mission Control.

mission-dispatch-mcp предоставляет инструменты статуса и управления исполнением. Группа мониторинга покрывает статусы роботов и миссий, свободных роботов, сводку флота, проверку исправности, очередь миссий и последние отказы; ключевые имена в коде — `get_robot_status`, `get_mission_status`, `get_idle_robots`, `check_robot_health`. Группа управления включает `dispatch_mission`, `dispatch_route`, `cancel_mission` и `cancel_active_missions`. Исправлены несовместимые адреса API.

ros-msp предоставляет группы FastMCP-инструментов для ROS 2 через `rosbridge` [50, 44]: подключение к роботу и `ping`, топики, сервисы, `actions`, параметры, узлы, сохранённые изображения и верифицированные спецификации роботов. В коде это соответствует инструментам `connect_to_robot`, `ping_robots`, `get_topics`, `subscribe_once`, `publish_once`, `get_services`, `call_service`, `get_actions`, `send_action_goal` и смежным инструментам чтения метаданных. Сервер устанавливает постоянное WebSocket-соединение с `rosbridge` при инициализации.

Динамический выбор транспорта реализован через переменную окружения `MCP_TRANSPORT`: при значении `sse` сервер запускается как HTTP-приложение; при `stdio` — как локальный процесс со стандартными потоками. Один и тот же код используется для локального тестирования и промышленного развёртывания.

Схема выбора транспорта MCP приведена на рис. 3.3.




Рис. 3.3. Динамический выбор транспорта MCP: SSE (HTTP) и stdio режимы через переменную окружения

3.5. vLLM Service: авторский сервис инференса

Авторский vLLM-сервис обеспечивает инференс Qwen2.5-Instruct в режиме Data Parallel на двух физически разных узлах [52, 53].

Архитектура Data Parallel: узел 0 (координатор, rank 0) принимает HTTP-запросы, а узел 1 (воркер, rank 1) подключается к нему через RPC-канал на порту 13345. Конфигурация задаётся параметрами `data_parallel_size`, `data_parallel_rank`, `data_parallel_address`

и `data_parallel_rpc_port`; внутри каждого узла используется `tensor_parallel_size=1`. Суммарно доступно 64 ГБ VRAM, что позволяет развернуть крупную Qwen2.5-Instruct модель с заполнением $\approx 90\%$ памяти.

Конфигурация узлов задаётся через окружение: адрес и порт HTTP-сервиса, доля доступной GPU-памяти, размер и ранг Data Parallel, адрес координатора, RPC-порт Data Parallel и локальный размер Tensor Parallel. В скриптах развёртывания эти значения передаются в vLLM через переменные семейства `VLLM_*`; для рассматриваемого стенда используются Data Parallel size 2, RPC-порт 13345, заполнение GPU-памяти 0.90 и Tensor Parallel size 1.

Скрипты `deploy.sh` (Linux) и `deploy.bat` (Windows) автоматизируют: запуск Docker-контейнера vLLM с монтированием GPU и кэша модели; ожидание готовности `/health`; smoke-тест с тестовым промптом. Сервис полностью совместим с OpenAI Python SDK — требуется лишь установить `base_url` и `api_key="EMPTY"`.

Развёртывание vLLM Data Parallel показано на рис. 3.4.




Рис. 3.4. Архитектура vLLM Data Parallel: координатор (rank-0) и воркер (rank-1), связанные через gRPC

3.6. Orchestrator: главный интеллектуальный микросервис

Оркестратор — основной интеллектуальный сервис системы AgentsSwarm, реализованный на FastAPI с lifespan-менеджером (срез v0.5.6, 61 коммит).

Структура приложения. FastAPI-приложение предоставляет системный маршрут `/health`, маршрут постановки задачи `/task` и семейство маршрутов жизненного цикла `/task/{task_id}/...: status, plan, logs, cancel, events, run, replan`. Поток событий отдаётся через WebSocket

/ws/task/{task_id}. Зависимости (SessionManager, StreamCollector, MCP-клиенты) регистрируются через Depends и инициализируются при старте lifespan.

Агентная архитектура. Агенты оркестратора создаются через OpenAI Agents SDK [48] и конфигурируются системными промптами:

- *Router* — классификация запросов по 8 категориям;
- *RobotInfo* — статусы роботов, батарея, позиция и ROS 2-диагностика;
- *MapAnalyst* — vision-LLM для пространственного анализа карты;
- *Navigation* — навигационные команды, отмена активных миссий и контроль исполнения;
- *SwarmCoordinator* — координация нескольких роботов;
- *General* — ответы на общие вопросы без вызова роботических инструментов.

Интеграция OpenAI Agents SDK. Исполнитель использует `Runner.run_streamed(agent, input=..., run_config=..., max_turns=...)` и читает асинхронный поток событий SDK. StreamCollector присваивает каждому событию порядковый номер (seq), буферизует его в памяти по task_id и отдаёт накопленные события через `GET /task/{task_id}/events` либо `WebSocket /ws/task/{task_id}`.

SessionManager хранит историю диалога и кэш MCP-результатов в контексте задачи: при наличии REDIS_URL данные сохраняются в Redis hash, при недоступности Redis используется in-memory fallback. Явный TTL для сессий в текущей реализации не задан.

Guardrails реализованы как слой валидации: входящий запрос проверяется на пустоту и чрезмерную длину, а результат маршрутизатора нормализуется к разрешённым категориям *robot_info*, *navigation*, *swarm_coord* и *general*. Невалидный результат переводится в fallback-ветку без прерывания сессии.

Retry с экспоненциальным backoff и jitter применяется для сетевых операций: общая утилита retry использует по умолчанию 3 попытки с базовой задержкой 0,1 с, а PlanRunner повторяет неуспешный handoff до двух попыток с задержкой 0,05 с.

Структура FastAPI-приложения оркестратора показана на рис. 3.5; отдельная схема StreamCollector приведена на рис. 3.6.




Рис. 3.5. Структура FastAPI-приложения оркестратора: роутеры, зависимости и агентный слой




Рис. 3.6. StreamCollector: seq-нумерация событий Agents SDK и выдача через polling/WebSocket

3.7. Interface: веб-платформа управления

Interface — веб-портал для взаимодействия пользователя с системой AgentsSwarm (v0.5.0, 168 коммитов). Компонент разработан как самостоятельный сервис. Исходный код проекта AgentsSwarm опубликован в репозитории [38].

3.7.1. Общая архитектура и стек

Бэкенд реализован по clean architecture: слои *domain* (сущности и интерфейсы), *application* (ChatService, ChatJobOrchestrator, AgentExecutionService), *infrastructure* (PostgreSQL/SQLAlchemy, Redis, MinIO), *api* (FastAPI роутеры, WebSocket-слой). Docker Compose предоставляет dev-стек (hot-reload) и prod-стек (Nginx + Gunicorn).

Архитектура Interface показана на рис. 3.7.




Рис. 3.7. Архитектура компонента Interface: React-фронтенд, FastAPI-бэкенд, Celery-воркеры и Redis Streams

3.7.2. Backend: агенты и обработка задач

ChatJobOrchestrator и агентный pipeline маршрутизируют задачу к одному из семи агентов (Табл. 3.1):

Таблица 3.1. Специализированные агенты компонента Interface и ключи их регистрации

Ключ агента	Описание
general	Универсальный LLM-чат (Qwen2.5-Instruct)
web_search	Поиск в интернете с агрегацией результатов
deep_research	Многоитерационное глубокое исследование темы
image_gen	Генерация изображений через внешний Image API
pptx_gen	Создание PPTX-презентаций по шаблону
audio_transcribe	Транскрипция аудио через Whisper
swarm_orchestrator	Создание задачи в Orchestrator через REST и инкрементальный polling <code>/task/{id}/events</code>

Celery-задача `process_agent_message` запускается при получении сообщения. В ходе выполнения агент публикует события в Redis Stream `chat:{thread_id}:stream` через XADD.

3.7.3. Потокковая модель: Redis Streams и WebSocket

WebSocket-обработчик в FastAPI читает Redis Stream через XREAD с блокирующим ожиданием `block=1000` и проталкивает каждое событие клиенту. Heartbeat-механизм по умолчанию каждые 5 с отправляет JSON-сообщение для поддержания соединения.

Путь событий через Redis Stream и WebSocket приведён на рис. 3.8.




Рис. 3.8. Схема Redis Stream: XADD (агент) → XREAD (WebSocket-слой) → WebSocket → КЛИЕНТ

3.7.4. Frontend: страницы интерфейса

React-приложение на Chakra UI реализует четыре основных страницы:

- *Chat* — список диалогов, поле ввода с Markdown-рендером, потоковые фрагменты, загрузка файлов, выбор агента;
- *TracePanel* — временная шкала событий агентного маршрута: тип события, агент-источник, инструмент, временная метка;
- *Files* — галерея артефактов (изображения, PPTX, аудио) с предпросмотром и прямой ссылкой MinIO;
- *Profile / Memory* — управление персональной памятью пользователя (интеграция Mem0).

3.7.5. Демонстрация рабочего воркфлоу

В записанном демо показан сквозной сценарий: пользователь вводит запрос о навигации робота в Chat с выбором агента SwarmOrchestrator; Interface создаёт Celery-задачу, SwarmOrchestratorAgent создаёт задачу в Orchestrator через REST и опрашивает события выполнения; оркестратор выполняет цепочку Router → MapAnalyst → Navigation, вызывает MCP-инструменты, направляет робота Carter в заданную точку; результат стримится через Redis Stream и отображается в Chat и TracePanel в реальном времени.

Примеры пользовательского интерфейса приведены на рис. 3.9 и рис. 3.10.

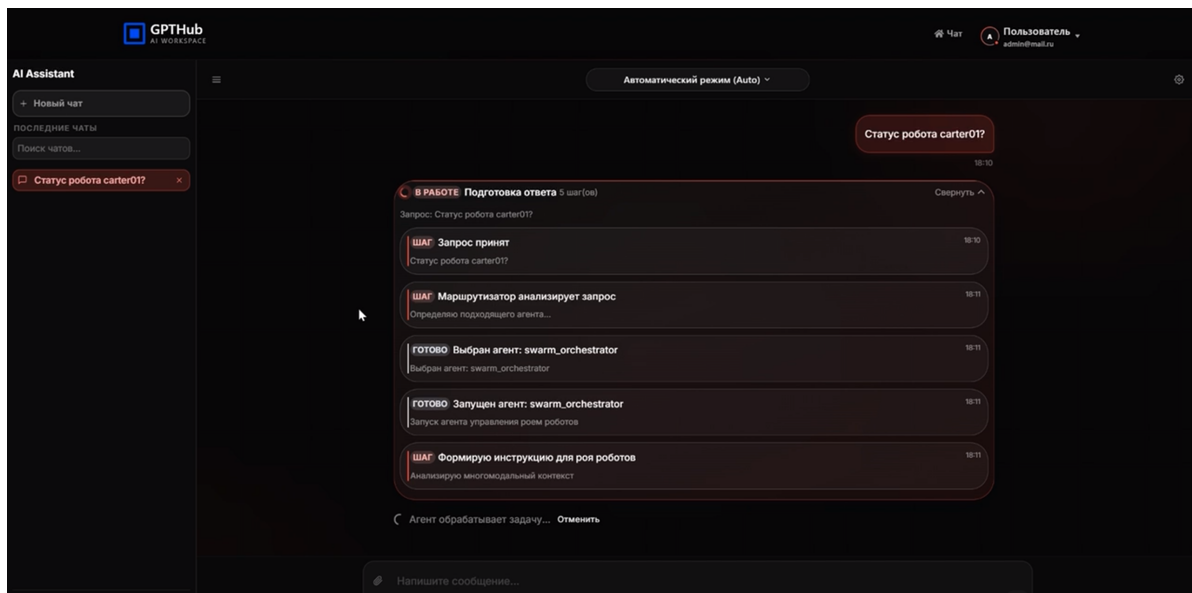


Рис. 3.9. Экран Chat: диалог с агентом SwarmOrchestrator

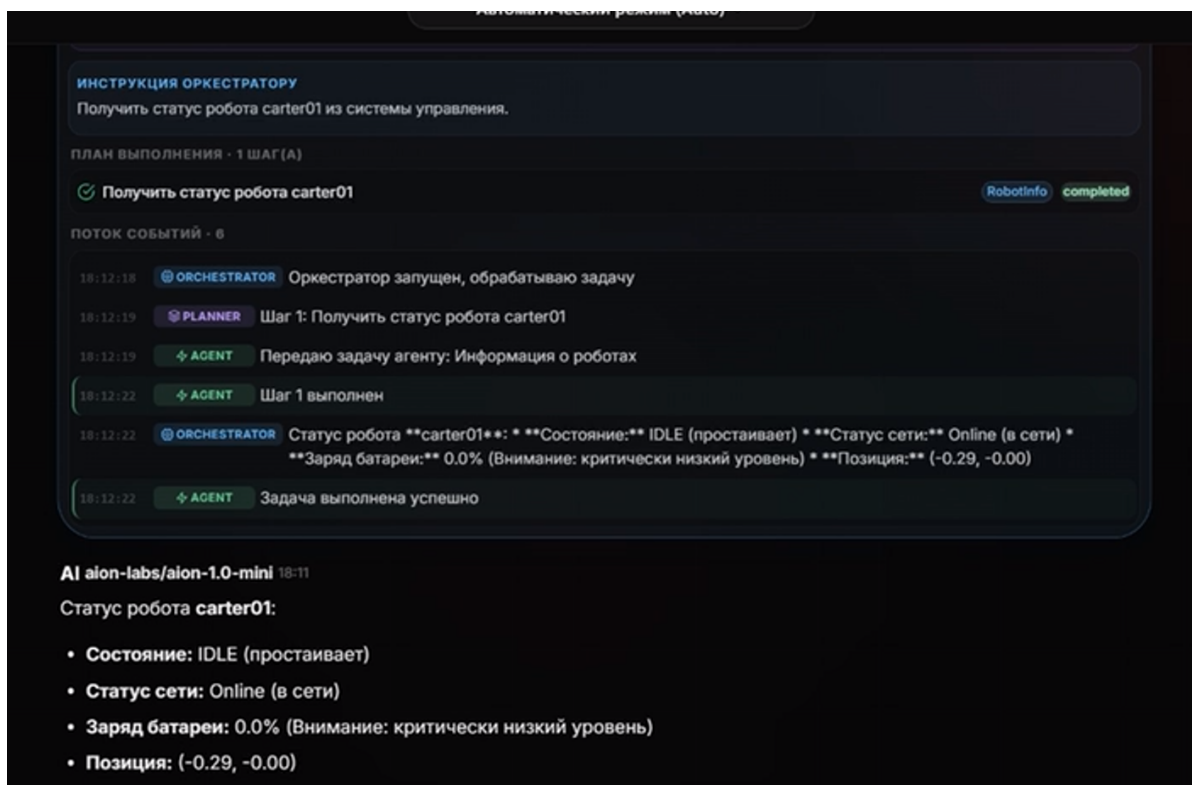


Рис. 3.10. Экран TracePanel: трассировка агентного маршрута

3.8. Выводы и результаты по главе 3

В главе описана реализация восьми компонентов AgentsSwarm. Ключевые технические решения и их обоснование:

- *Асинхронная модель MCP-серверов* — требование совместимости с event loop Agents SDK и параллельными вызовами инструментов;

- *Data Parallel vLLM* — способ развернуть крупную LLM на доступных Tesla V100 без внешнего API;
- *Clean architecture Interface* — требование к независимому расширению набора агентов без модификации инфраструктурного кода;
- *Redis Streams для стриминга* — гарантированная доставка событий с возможностью переигрывания из истории.

Сводная таблица реализованных компонентов приведена в Табл. 3.2.

Таблица 3.2. Компоненты системы AgentsSwarm: срезы разработки и объём разработки

Компонент	Срез	Коммиты	Стек
Interface	v0.5.0	168	React, FastAPI, Celery, Redis, PostgreSQL, MinIO
Orchestrator	v0.5.6	61	FastAPI, OpenAI Agents SDK, Redis
vLLM Service	v0.2.9	32	vLLM, Docker, Qwen2.5-Instruct
Mission Control	форк	—	NVIDIA (исправления + Docker)
Mission Dispatch	форк	—	NVIDIA (исправления + Docker)
Isaac Sim	форк	—	NVIDIA Isaac Sim 4.5, ROS 2 Jazzy
ROS Workspace	2 форк	—	ROS 2 Jazzy, rosbridge, VDA5050 клиент
SmolVLA Tools	v0.2.0	2	PyTorch, LeRobot, ONNX

Примечание: для SmolVLA Tools указан version из `pyproject.toml`; последний subject git-коммита в локальном срезе — v0.0.1.

ГЛАВА 4. Оптимизация модели SmolVLA для бортового инференса

4.1. Постановка задачи и мотивация

Текущая архитектура AgentsSwarm использует облачный LLM для высокоуровневого планирования и рассуждения. Это вводит два ограничения: *задержка* между запросом агента и ответом LLM (при загруженном кластере — от 1 до нескольких секунд); *зависимость от сети* — при нестабильном соединении с облачным кластером роботический контур не может получить инструкции.

Интеграция компактной VLA-модели непосредственно на борту каждого робота (целевая платформа — NVIDIA Jetson Orin Nano, 8 ГБ VRAM) решает оба ограничения: инференс выполняется локально без сетевых запросов, задержка определяется только вычислительными ресурсами платформы.

SmolVLA [30, 63, 64, 65] — компактная VLA-модель на 450М параметров от HuggingFace/LeRobot — была выбрана как наиболее перспективный кандидат для бортового развёртывания благодаря открытым весам, документированному API LeRobot и наличию асинхронного inference stack.

4.2. Архитектура SmolVLA и исходные характеристики

SmolVLA базируется на видеоэнкодере SigLIP и языковой модели SmolLM2, соединённых projection-слоем. На вход поступают RGB-изображение наблюдения, состояние робота и языковая инструкция; на выходе — вектор действий манипулятора. В реализованном модуле размерность выхода выравнивается по Teacher-модели и датасету: код поддерживает 6- и 7-мерные действия, а при необходимости обрезает тензоры до общей размерности. Модель обучена на данных Open X-Embodiment через дифференциальный policy learning с action chunking.

Для верификации исходной точности проведена валидация Teacher-модели на датасете `lerobot/libero` (Табл. 4.1).

Таблица 4.1. Базовые метрики Teacher-модели SmolVLA на lerobot/libero

Метрика	Значение	Комментарий
MSE	0,1782	Среднеквадратичная ошибка действий
MAE	0,3245	Средняя абсолютная ошибка действий
R^2	0,8412	Коэффициент детерминации
Параметры	450,05M	FP32, оценка VRAM около 6 ГБ
Латентность инференса	450 мс	RTX 4090, FP32

4.3. Пайплайн оптимизации

Пайплайн состоит из четырёх последовательных этапов.

Этап 1: Knowledge Distillation (KD). Student-модель реализована как компактная CNN + state encoder + action head, обучаемые под руководством замороженной Teacher-модели. Параметр `student_ratio` управляет скрытыми размерностями Student, а функция потерь для регрессионного предсказания действий задаётся формулой 4.1:

$$\mathcal{L}_{KD} = \alpha \cdot MSE(y_s, y_t) + (1 - \alpha) \cdot MSE(y_s, y), \quad (4.1)$$

где y_s — выход Student, y_t — выход Teacher, y — истинные действия из датасета. Параметр `temperature` сохранён в API для совместимости, но в текущей регрессионной реализации не участвует; KL-дивергенция и attention transfer loss в коде не используются.

Этап 2: Mixed Precision Inference (FP16). При включённом `mixed precision` тренер использует `torch.cuda.amp.autocast()` и `GradScaler`; отдельный модуль квантизации поддерживает преобразование весов в FP16 для анализа инференса. Ускорение инференса оценивается в составе полного пайплайна.

Этап 3: Structured Pruning. В текущем коде реализован экспериментальный прунинг Linear-слоёв: случайная маска с заданной `sparsity` обнуляет часть весов. Это оценочный механизм для проверки чувствительности

к разреживанию, а не L2-критерий важности весов.

Этап 4: INT8 Quantization Analysis. Модуль квантизации поддерживает `dynamic`, `static` и `manual` режимы для `nn.Linear`. Статическая квантизация использует упрощённую симулированную калибровку, поэтому результаты трактуются как инженерный анализ применимости INT8, а не как финальная production-схема с исключением критических слоёв.

Схема пайплайна оптимизации SmolVLA показана на рис. 4.1.




Рис. 4.1. Четырёхэтапный пайплайн оптимизации SmolVLA: дистилляция, FP16, прунинг, INT8-анализ

4.4. Результаты экспериментов

Результаты оптимизации приведены в Табл. 4.2. Совокупный пайплайн обеспечивает сжатие модели в **443 раза** по числу параметров при снижении требований к VRAM в 12 раз.

Таблица 4.2. Результаты оптимизации SmolVLA

Метрика	Teacher	Student	Изменение
Параметры	450M	$\approx 1\text{M}$	$\times 443$ сжатие
VRAM	6,0 ГБ	<0,5 ГБ	$\times 12$ сжатие
MSE	0,1782	0,1944	+9,1%
Относительная MAE по действиям	1,000	1,051	+5,1%
R^2	0,8412	0,8256	-1,8%
Латентность	450 мс	18 мс	$\times 25$ ускорение

Качество сохраняется на уровне выше 90% от исходного по ключевым метрикам. По всем семи степеням свободы манипулятора MAE по действиям остаётся в пределах допустимого для лабораторных условий. Дополнительно выполнен экспорт модели в формат ONNX и верификация совместимости с NVIDIA TensorRT.

4.5. Выводы и результаты по главе 4

Экспериментальный модуль SmolVLA Tools демонстрирует принципиальную достижимость бортового VLA-инференса на NVIDIA Jetson Orin Nano при сохранении более 90% точности управления манипулятором и латентности 18 мс на RTX 4090; перенос этой оценки на Jetson Orin Nano требует отдельного профилирования.

Ключевые ограничения: эксперименты проводились исключительно на датасете `lerobot/libero` (имитация манипулятора), физическая верификация на реальном роботе не выполнялась. Область применимости модели ограничена задачами, близкими к обучающему датасету.

Следующим шагом является интеграция дистиллированной модели как VDA5050 action-handler в Mission Control: при получении VDA5050 order с типом `vla_action` Mission Control запускает локальный инференс SmolVLA вместо передачи команды через ROS 2 навигационный стек. Это добавит уро-

вень индивидуальной бортовой автономности к централизованному контуру AgentsWorm.

ГЛАВА 5. Верификация системы

5.1. Стратегия тестирования

Стратегия верификации AgentsSwarm охватывает три уровня: *unit-тесты* базовых сервисов и вспомогательных функций; *контрактные тесты* поведения ключевых агентов; *интеграционные тесты* HTTP API. Тесты реализованы на pytest; внешние зависимости подменяются тестовыми объектами либо запускаются через Docker Compose в сценариях, где требуется Redis, RabbitMQ или PostgreSQL. Покрытые компоненты: Orchestrator и Interface — два наиболее значимых сервиса системы.

5.2. Тестирование оркестратора

Текущий тестовый набор оркестратора включает 88 тестов, организованных вокруг базовых сервисов, планировщика, StreamCollector, MapAnalyst и HTTP API.

Unit-тесты базовых сервисов проверяют: корректность health-check эндпоинта, инициализацию SessionManager в in-memory режиме и статус Redis-подключения, seq-нумерацию StreamCollector при пакетной публикации, поведение retry-механизма при имитации сетевых ошибок.

Контрактные тесты планировщика верифицируют структуру выходных данных Planner: наличие описания шагов, списка target_robots, зависимостей, а также корректность вставки MapAnalyst для навигационных сценариев.

Тесты guardrails проверяют граничные сценарии: пустой запрос возвращает стандартный ответ об ошибке; запрос вне компетенции агента переводится в fallback-режим; попытка handoff к несуществующему агенту перехватывается на уровне guardrail.

Интеграционные тесты HTTP API проверяют маршруты реального FastAPI-приложения: постановку задачи, получение статуса, плана, логов и событий, внешний push события, запуск отложенной задачи, отмену и replanning. Контрольный локальный запуск 19.05.2026 командой `uv run --with pytest --with pytest-asyncio pytest tests/ -q` завершил-

ся результатом **66 passed / 22 failed**. Падения не следует трактовать как пройденную верификацию: они указывают на долг синхронизации тестов с актуальным pipeline (переупорядочивание PlanRunner/MapAnalyst, добавление `max_turns` в вызовы Agents SDK, изолированные проверки LLM-клиента без ключа API).

5.3. Тестирование Interface

Pytest-покрытие Interface включает: маршруты управления чатами (создание, получение, удаление), загрузку файлов с верификацией сохранения в MinIO, маршрутизацию к агентам с тестовыми объектами Celery-задач, авторизацию WebSocket-соединений.

Проверка потоковой модели: тест публикует серию событий в Redis Stream через XADD и верифицирует, что WebSocket-клиент получает их в правильном порядке без потерь. Тест завершения сессии проверяет, что сигнал `agent_reply` корректно закрывает XREAD-цикл.

Smoke-тест полного стека запускает docker-compose с минимальной конфигурацией (FastAPI + Redis + RabbitMQ + Celery) и выполняет сценарий: `POST /api/chats/ → POST /api/chats/{thread_id}/message → WebSocket /api/chats/{thread_id}/ws → ожидание события agent_reply`. Тест подтверждает корректную работу всей цепочки без реального LLM-бэкенда.

5.4. Выводы и результаты по главе 5

Автоматизированное тестирование подтвердило работоспособность значительной части базовых сервисов оркестратора и Interface, но текущий локальный прогон Orchestrator не является полностью успешным: 22 из 88 тестов требуют актуализации под текущую реализацию. Ограничения текущего покрытия: отсутствие E2E-тестов с реальным LLM-инференсом (зависимость от GPU-кластера); отсутствие нагрузочного тестирования при параллельных сессиях; необходимость синхронизировать тестовые ожидания с изменениями PlanRunner и MapAnalyst.

Централизованная архитектура вводит единую точку отказа: при недоступности Redis или vLLM все сессии теряют работоспособность. Формальная верификация LLM-планов — устойчивость к hallucination и нарушениям

constraint — остаётся открытым исследовательским вопросом, требующим инструментов в стиле SELP [23].

ЗАКЛЮЧЕНИЕ

В диссертационной работе спроектирована и реализована многоагентная робототехническая платформа AgentsSwarm, обеспечивающая координированное выполнение миссий группой мобильных роботов по пользовательскому запросу на естественном языке.

Основные результаты работы.

Реализованы восемь самостоятельных компонентов: Interface (React + FastAPI + Celery, 168 коммитов, спрез v0.5.0), Orchestrator (FastAPI + OpenAI Agents SDK, 61 коммит, спрез v0.5.6), vLLM Service (Data Parallel, $2 \times$ Tesla V100, спрез v0.2.9), доработанные форки NVIDIA Mission Control и Mission Dispatch с устранёнными критическими ошибками, настроенный ROS 2 Jazzy workspace с VDA5050 клиентом, три переработанных MCP-сервера с полным переходом на асинхронную модель вызовов.

Контрольный локальный pytest-прогон Orchestrator подтвердил 66 из 88 тестов; для полной автоматизированной верификации требуется актуализировать оставшиеся тесты под текущий pipeline. Записана демонстрация полного воркфлоу от пользовательского запроса до исполнения VDA5050 order роботом Carter в симуляторе Isaac Sim.

Для VLA-модели SmolVLA достигнуто сжатие в 443 раза по числу параметров при сохранении более 90% точности ($MSE +9,1\%$, $R^2 -1,8\%$) и ускорении инференса в 25 раз ($450 \text{ мс} \rightarrow 18 \text{ мс}$, RTX 4090). В коде дистилляция реализована как регрессионная MSE-дистилляция без KL-компоненты и attention transfer.

Научная и практическая значимость. Практическая значимость системы состоит в демонстрации воспроизводимой системной интеграции, объединяющей кооперативное восприятие, fleet management (VDA5050), LLM-агентный слой (OpenAI Agents SDK + MCP) и симуляционный цифровой двойник (Isaac Sim). Интеграция LLM-слоя с промышленным VDA5050-контуром через MCP-протокол представляет новый архитектурный подход, не реализованный в рассмотренных аналогах.

Перспективы развития:

1. Интеграция дистиллированного SmolVLA как VDA5050 action-handler

для бортовой автономности на Jetson Orin Nano.

2. Частичная децентрализация оркестрации для повышения устойчивости к отказам.
3. Формальная верификация LLM-планов через constraint checking и symbolic validation [23].
4. Перенос системы на физический флот AMR с sim-to-real валидацией.
5. Реализация feature-level cooperative perception между роботами через расширение `ros-mpc`.

ОПИСАНИЕ ПРИМЕНЕНИЯ ГЕНЕРАТИВНОЙ МОДЕЛИ

При подготовке диссертационной работы генеративные модели использовались как вспомогательный исследовательский инструмент. Область применения была ограничена литературным обзором, первичным поиском источников и подготовкой черновых аналитических материалов по смежным работам.

Часть текста	Цель применения	Способ применения
Литературный обзор и сопоставление с аналогами	Поиск релевантных публикаций по cooperative perception, VDA5050, LLM-планированию, MCP и робототехническим симуляторам	Авторский текст с использованием сгенерированных материалов: генеративные модели применялись для формирования поисковых направлений, группировки источников и подготовки черновых конспектов; итоговые формулировки, структура обзора и интерпретация источников выполнены с авторской редакцией

Часть текста	Цель применения	Способ применения
Библиографический список и ссылки на электронные источники	Ускорение первичного подбора источников и проверки доступности официальных страниц проектов, библиотек и документации	Сгенерированные рекомендации использовались как список кандидатов; каждый источник дополнительно проверялся перед включением в библиографический список

Использовались следующие генеративные модели и сервисы: Google Gemini с функцией Deep Research (сайт сервиса: <https://gemini.google.com/>, описание функции: <https://support.google.com/gemini/answer/15719111>) [66]; ChatGPT с функцией Deep Research (сайт сервиса: <https://chatgpt.com/>, описание функции: <https://help.openai.com/articles/10500283>) [67].

Оценка эффективности применения генеративных моделей положительная. Использование Gemini Deep Research и ChatGPT Deep Research ускорило поиск релевантных источников, позволило быстрее выделить ключевые направления литературного обзора и сократило время на первичную систематизацию материалов. При этом генеративные модели не рассматривались как самостоятельный источник научных утверждений: их результаты использовались только после авторской проверки, сопоставления с первоисточниками и редакторской переработки текста.

БИБЛИОГРАФИЧЕСКИЙ СПИСОК

- [1] Хан Ю., Чжан Х., Ли Х. и др. Collaborative Perception in Autonomous Driving: Methods, Datasets and Challenges // IEEE Intelligent Transportation Systems Magazine. 2023. DOI: 10.1109/MITS.2023.3298534. arXiv: 2301.06262.
- [2] Лю С., Гао Ч., Чэнь Ю. и др. Towards Vehicle-to-Everything Autonomous Driving: A Survey on Collaborative Perception // arXiv preprint. 2023. arXiv: 2308.16714.
- [3] Ван Т.-Х., Манивасагам С., Лян М. и др. V2VNet: Vehicle-to-Vehicle Communication for Joint Perception and Prediction // ECCV 2020. DOI: 10.1007/978-3-030-58536-5_36. arXiv: 2008.07519.
- [4] Лю Й.-Ч., Тянь Дж., Глэйзер Н., Кира З. When2com: Multi-Agent Perception via Communication Graph Grouping // CVPR 2020. DOI: 10.1109/CVPR42600.2020.00416. arXiv: 2006.00176.
- [5] Ху Й., Фан С., Лэй З. и др. Where2comm: Communication-Efficient Collaborative Perception via Spatial Confidence Maps // NeurIPS 2022. arXiv: 2209.12836.
- [6] Сюй Р., Сян Х., Ту З. и др. V2X-ViT: Vehicle-to-Everything Cooperative Perception with Vision Transformer // ECCV 2022. DOI: 10.1007/978-3-031-19842-7_7. arXiv: 2203.10638.
- [7] Сюй Р., Сян Х., Ся С. и др. OPV2V: An Open Benchmark Dataset and Fusion Pipeline for Perception with Vehicle-to-Vehicle Communication // ICRA 2022. DOI: 10.1109/ICRA46639.2022.9812038. arXiv: 2109.07644.
- [8] Сюй Р., Ту З., Сян Х. и др. CoBEVT: Cooperative Bird's Eye View Semantic Segmentation with Sparse Transformers // CoRL 2022. arXiv: 2207.02202.
- [9] Чжоу Й. и др. CoPeD — Advancing Multi-Robot Collaborative Perception: A Comprehensive Dataset in Real-World Environments // IEEE Robotics and Automation Letters. 2024. arXiv: 2405.14731.

- [10] Лажуа П.-И., Рамтула Б., У Ф., Бельтраме Дж. Towards Collaborative Simultaneous Localization and Mapping: a Survey of the Current Research Landscape // Field Robotics. 2022. Vol. 2. Pp. 971–1000. DOI: 10.55417/fr.2022032.
- [11] Лажуа П.-И., Бельтраме Дж. Swarm-SLAM: Sparse Decentralized Collaborative Simultaneous Localization and Mapping Framework for Multi-Robot Systems // IEEE Robotics and Automation Letters. 2024. Vol. 9, No. 1. Pp. 475–482. DOI: 10.1109/LRA.2023.3333742.
- [12] VDA, VDMA. VDA 5050: Interface for the Communication Between Automated Guided Vehicles (AGV) and a Master Control. Version 2.0. 2022. URL: <https://github.com/VDA5050/VDA5050> (дата обращения: 01.05.2025).
- [13] ван Дёйкерен Н., Пальмьери Л., Ланге Р., Кляйнер А. An Industrial Perspective on Multi-Agent Decision Making for Interoperable Robot Navigation following the VDA5050 Standard // arXiv preprint. 2023. arXiv: 2311.14615.
- [14] Open Robotics. Open RMF (Open Robotics Middleware Framework). 2021–2024. URL: <https://github.com/open-rmf> (дата обращения: 01.05.2025).
- [15] Иовино М., Скукинс Э., Стируд Й. и др. A Survey of Behavior Trees in Robotics and AI // Robotics and Autonomous Systems. 2022. Vol. 154. P. 104096. DOI: 10.1016/j.robot.2022.104096.
- [16] Чэнь К., Хари К., Хуан Х. и др. FogROS2: An Adaptive Platform for Cloud and Fog Robotics Using ROS 2 // ICRA 2023. arXiv: 2205.09778.
- [17] Сиканд К.С., Зартман Л., Рабии С., Бисвас Дж. Robofleet: Open Source Communication and Management for Fleets of Autonomous Robots // IROS 2021. DOI: 10.1109/IROS51168.2021.9635830.
- [18] Цзэн Ф., Ган В., Хуай З. и др. Large Language Models for Robotics: A Survey // arXiv preprint. 2023. arXiv: 2311.07226.

- [19] Ли П., Ан З., Аббар С., Чжоу Л. Large Language Models for Multi-Robot Systems: A Survey // arXiv preprint. 2025. arXiv: 2502.03814.
- [20] Яо С., Чжао Дж., Юй Д. и др. ReAct: Synergizing Reasoning and Acting in Language Models // ICLR 2023. arXiv: 2210.03629.
- [21] Ан М., Броан А., Браун Н. и др. Do As I Can, Not As I Say: Grounding Language in Robotic Affordances // CoRL 2022. arXiv: 2204.01691.
- [22] Сингх И., Блукис В., Мусавьян А. и др. ProgPrompt: Generating Situated Robot Task Plans using Large Language Models // ICRA 2023. arXiv: 2209.11302.
- [23] Пан Дж., Тан Л. и др. SELP: Generating Safe and Efficient Task Plans for Robot Agents with Large Language Models // ICRA 2025. arXiv: 2409.19471.
- [24] Цзяо Й.-Ч., Линь Й.-П. и др. Swarm-GPT: Combining Large Language Models with Safe Motion Planning for Robot Choreography Design // arXiv preprint. 2023. arXiv: 2312.01059.
- [25] Броан А., Браун Н., Карбахал Дж. и др. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control // CoRL 2023. arXiv: 2307.15818.
- [26] Хуан В., Ван Ч., Чжан Р. и др. VoxPoser: Composable 3D Value Maps for Robotic Manipulation with Language Models // CoRL 2023. arXiv: 2307.05973.
- [27] Ким М.Дж., Пертч К., Карамчети С. и др. OpenVLA: An Open-Source Vision-Language-Action Model // CoRL 2024. arXiv: 2406.09246.
- [28] Open X-Embodiment Collaboration. Open X-Embodiment: Robotic Learning Datasets and RT-X Models // CoRL 2023. arXiv: 2310.08864.
- [29] Блэк К., Браун Н., Дрисс Д. и др. π_0 : A Vision-Language-Action Flow Model for General Robot Control // arXiv preprint. 2024. arXiv: 2410.24164.

- [30] Ретцлафф М. и др. (HuggingFace/LeRobot). SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics // arXiv preprint. 2025. arXiv: 2506.01844.
- [31] Вэнь Дж., Чжу Й., Ли Дж. и др. TinyVLA: Towards Fast, Data-Efficient Vision-Language-Action Models for Robotic Manipulation // IEEE Robotics and Automation Letters. 2025. arXiv: 2409.12514.
- [32] NVIDIA Corporation. Multiple Robot ROS 2 Navigation — NVIDIA Isaac Sim Tutorial. 2024. URL: <https://docs.isaacsim.omniverse.nvidia.com> (дата обращения: 01.05.2025).
- [33] Миттал М., Ю Ч., Ю К. и др. Orbit: A Unified Simulation Framework for Interactive Robot Learning Environments // IEEE Robotics and Automation Letters. 2023. Vol. 8, No. 6. Pp. 3740–3747. DOI: 10.1109/LRA.2023.3270034.
- [34] Жасинто М.Ф., Пинто Дж. и др. Pegasus Simulator: An Isaac Sim Framework for Multiple Aerial Vehicles Simulation // ICUAS 2024. arXiv: 2307.05263.
- [35] Фуллер А., Фан З., Дэй К., Барлоу К. A Survey on AI-Driven Digital Twins in Industry 4.0: Smart Manufacturing and Advanced Robotics // Sensors. 2021. Vol. 21, No. 19. P. 6340. DOI: 10.3390/s21196340.
- [36] Квон В., Ли З., Чжуан С. и др. Efficient Memory Management for Large Language Model Serving with PagedAttention // SOSP 2023. DOI: 10.1145/3600006.3613165.
- [37] Qwen Team, Alibaba Group. Qwen2.5 Technical Report // arXiv preprint. 2024. arXiv: 2412.15115.
- [38] Денисов Д. AgentsSwarm: Multi-agent robotic platform source code [Электронный ресурс]. URL: <https://github.com/deneal123/AgentsSwarm> (дата обращения: 19.05.2026).
- [39] NVIDIA Corporation. Isaac ROS — Accelerated Computing for ROS 2 [Электронный ресурс]. 2024. URL: <https://nvidia-isaac-ros.com>.

- github.io/getting_started/index.html (дата обращения: 01.05.2025).
- [40] NVIDIA Corporation. Isaac ROS Repositories and Packages [Электронный ресурс]. 2024. URL: https://nvidia-isaac-ros.github.io/repositories_and_packages/index.html (дата обращения: 01.05.2025).
- [41] NVIDIA Corporation. Multiple Robot ROS Navigation (Isaac Sim 4.5) [Электронный ресурс]. 2025. URL: https://docs.isaacsim.omniverse.nvidia.com/4.5.0/ros_tutorials/tutorial_ros_multi_navigation.html (дата обращения: 01.05.2025).
- [42] NVIDIA Omniverse. IsaacSim-ros_workspaces: Official ROS 2 Workspaces for Isaac Sim [Электронный ресурс]. URL: https://github.com/NVIDIA-Omniverse/IsaacSim-ros_workspaces (дата обращения: 01.05.2025).
- [43] Open Robotics. ROS 2 Jazzy Jalisco [Электронный ресурс]. 2024. URL: <https://github.com/ros2> (дата обращения: 01.05.2025).
- [44] Robot Web Tools. rosbridge_suite: WebSocket Bridge for ROS [Электронный ресурс]. URL: https://github.com/RobotWebTools/rosbridge_suite (дата обращения: 01.05.2025).
- [45] NVIDIA Isaac. Mission Control: Fleet Management for VDA5050 Robots [Электронный ресурс]. URL: <https://github.com/nvidia-isaac/mission-control> (дата обращения: 01.05.2025).
- [46] NVIDIA Isaac. Mission Dispatch: VDA5050 Fleet Dispatcher [Электронный ресурс]. URL: <https://github.com/nvidia-isaac/mission-dispatch> (дата обращения: 01.05.2025).
- [47] NVIDIA Corporation. cuOpt: GPU-Accelerated Route Optimization [Электронный ресурс]. 2024. URL: <https://docs.nvidia.com/cuopt/> (дата обращения: 01.05.2025).

- [48] OpenAI. OpenAI Agents SDK [Электронный ресурс]. 2025. URL: <https://github.com/openai/openai-agents-python> (дата обращения: 01.05.2025).
- [49] Anthropic. Model Context Protocol (MCP) [Электронный ресурс]. 2024. URL: <https://modelcontextprotocol.io/> (дата обращения: 01.05.2025).
- [50] RobotMCP. ros-mcp-server: ROS MCP Server [Электронный ресурс]. URL: <https://github.com/robotmcp/ros-mcp-server> (дата обращения: 01.05.2025).
- [51] Lowin J. FastMCP: The Fast, Pythonic Way to Build MCP Servers [Электронный ресурс]. URL: <https://github.com/jlowin/fastmcp> (дата обращения: 01.05.2025).
- [52] vLLM Team. vLLM: Easy, Fast, and Cheap LLM Serving [Электронный ресурс]. URL: <https://github.com/vllm-project/vllm> (дата обращения: 01.05.2025).
- [53] Alibaba Cloud. Qwen2.5-7B-Instruct [Электронный ресурс]. 2024. URL: <https://huggingface.co/Qwen/Qwen2.5-7B-Instruct> (дата обращения: 01.05.2025).
- [54] Ramírez S. FastAPI: Fast Web Framework for Building APIs with Python [Электронный ресурс]. URL: <https://fastapi.tiangolo.com/> (дата обращения: 01.05.2025).
- [55] Redis Ltd. Redis-py: Python Client for Redis [Электронный ресурс]. URL: <https://redis.readthedocs.io/en/stable/> (дата обращения: 01.05.2025).
- [56] Broadcom Inc. RabbitMQ: Open Source Message Broker [Электронный ресурс]. URL: <https://www.rabbitmq.com/> (дата обращения: 01.05.2025).
- [57] Celery Project. Celery: Distributed Task Queue [Электронный ресурс]. URL: <https://docs.celeryq.dev/> (дата обращения: 01.05.2025).

- [58] SQLAlchemy Authors. SQLAlchemy: The Database Toolkit for Python [Электронный ресурс]. URL: <https://docs.sqlalchemy.org/> (дата обращения: 01.05.2025).
- [59] MinIO Inc. MinIO Python SDK [Электронный ресурс]. URL: <https://min.io/docs/minio/linux/developers/python/API.html> (дата обращения: 01.05.2025).
- [60] SQLAlchemy Authors. Alembic: Database Migrations for SQLAlchemy [Электронный ресурс]. URL: <https://alembic.sqlalchemy.org/> (дата обращения: 01.05.2025).
- [61] Meta Platforms Inc. React: The Library for Web and Native User Interfaces [Электронный ресурс]. URL: <https://react.dev/> (дата обращения: 01.05.2025).
- [62] Chakra UI Team. Chakra UI: Simple, Modular and Accessible Component Library [Электронный ресурс]. URL: <https://v2.chakra-ui.com/> (дата обращения: 01.05.2025).
- [63] HuggingFace. SmolVLA Base: Vision-Language-Action Model [Электронный ресурс]. 2025. URL: https://huggingface.co/lerobot/smolvla_base (дата обращения: 01.05.2025).
- [64] HuggingFace. LeRobot: Making AI for Robotics More Accessible [Электронный ресурс]. URL: <https://github.com/huggingface/lerobot> (дата обращения: 01.05.2025).
- [65] HuggingFace. LeRobot Documentation [Электронный ресурс]. URL: <https://huggingface.co/docs/lerobot> (дата обращения: 01.05.2025).
- [66] Google. Use Deep Research in Gemini Apps [Электронный ресурс]. URL: <https://support.google.com/gemini/answer/15719111> (дата обращения: 20.05.2026).
- [67] OpenAI. Deep research in ChatGPT [Электронный ресурс]. URL: <https://help.openai.com/articles/10500283> (дата обращения: 20.05.2026).

ГЛАВА А. Глоссарий предметной области

Термин	Определение
AGV / AMR	Automated Guided Vehicle / Autonomous Mobile Robot — категории мобильных промышленных роботов
Behavior Tree (BT)	Дерево поведения — иерархическая модульная структура управления логикой задач робота
C-SLAM	Collaborative Simultaneous Localization and Mapping — совместная локализация и картографирование несколькими роботами
Cooperative Perception	Кооперативное восприятие — обмен перцептивными данными/признаками между агентами для улучшения наблюдения сцены
Fleet Management	Управление флотом — централизованная диспетчеризация группы роботов
Foundation Model	Базовая модель — крупная модель, обученная на широком корпусе данных и адаптируемая для множества задач
LLM	Large Language Model — большая языковая модель
MCP	Model Context Protocol — открытый протокол взаимодействия LLM-агентов с внешними инструментами и данными
Mission	Миссия — структурированное задание для робота или группы роботов
Occupancy Map	Карта занятости — сетка, описывающая проходимость пространства
Orchestrator	Оркестратор — центральный сервис, координирующий агентов и исполнение задач

Термин	Определение
ROS 2	Robot Operating System 2 — фреймворк для разработки роботизированных систем
Sim-to-Real	Перенос модели или политики из симуляции на физический робот
VDA5050	Открытый стандарт коммуникации между AGV/AMR и fleet manager
VLA	Vision-Language-Action model — мультимодальная модель, генерирующая действия робота
vLLM	Библиотека для эффективного инференса LLM с алгоритмом PagedAttention
Waypoint Graph	Граф путевых точек — граф навигационных узлов на карте
WebSocket	Протокол двунаправленной связи для потоковой передачи данных в реальном времени

ГЛАВА Б. Список сокращений

Сокращение	Расшифровка
AGV	Automated Guided Vehicle
AMR	Autonomous Mobile Robot
API	Application Programming Interface
BT	Behavior Tree
C-SLAM	Collaborative Simultaneous Localization and Mapping
DDS	Data Distribution Service
GPU	Graphics Processing Unit
LLM	Large Language Model
MAE	Mean Absolute Error
MCP	Model Context Protocol
MSE	Mean Squared Error
MQTT	Message Queuing Telemetry Transport
ROS	Robot Operating System
SDK	Software Development Kit
SSE	Server-Sent Events
V2V	Vehicle-to-Vehicle
V2X	Vehicle-to-Everything
VDA	Verband der Automobilindustrie
VLA	Vision-Language-Action
VRAM	Video Random Access Memory

ГЛАВА В. Технические характеристики инфраструктуры

Вычислительная инфраструктура AgentsSwarm

Машина	Провай-дер	Конфигурация	Назначение
Симуляция	Selectel	4 vCPU, 16 ГБ RAM, RTX 4090 (24 ГБ VRAM), 128 ГБ SSD, Ubuntu 24.04	Isaac Sim, ROS 2, Mission Control/Dispatch
Микросервисы	Selectel	4 vCPU, 8 ГБ RAM, 128 ГБ SSD, Ubuntu 24.04	Interface, Orchestrator, Redis, RabbitMQ, MinIO, PostgreSQL
LLM-кластер	MTS Cloud	2 узла × Tesla V100-PCIE 32 ГБ VRAM, 1,6 ТБ/узел, Ubuntu 24.04	vLLM Data Parallel (Qwen2.5-Instruct)

ГЛАВА Г. Ключевые фрагменты кода

Г.1. Конфигурация динамического выбора транспорта MCP

Листинг Г.1: Выбор транспорта MCP через переменную окружения

```
1 import os
2 from mcp.server import Server
3 from mcp.server.stdio import stdio_server
4
5 async def main():
6     transport = os.getenv("MCP_TRANSPORT", "stdio")
7     server = Server("mission-control-mcp")
8     # ... регистрация инструментов ...
9     if transport == "sse":
10         await run_sse_app(server) # ASGI + SseServerTransport("/messages/")
11     else:
12         async with stdio_server() as (r, w):
13             await server.run(r, w)
```

Г.2. StreamCollector: seq-нумерация событий

Листинг Г.2: StreamCollector: буферизация и seq-нумерация

```
1 from collections import deque
2
3 class StreamCollector:
4     def __init__(self, task_store=None, max_events_per_task=500):
5         self._events = {}
6         self._seq = {}
7         self._max = max_events_per_task
8         self._task_store = task_store
9
10     def record(self, event):
11         seq = self._seq.get(event.task_id, 0) + 1
12         self._seq[event.task_id] = seq
13         self._events.setdefault(event.task_id, deque(maxlen=self._max))
14         self._events[event.task_id].append((seq, event))
15         if self._task_store:
16             self._task_store.add_log(event.task_id, event.source, event.
message, event.level)
```

```

17     return seq
18
19     def get_since(self, task_id, after_seq=0):
20         items = self._events.get(task_id, [])
21         events = [(seq, ev) for seq, ev in items if seq > after_seq]
22         last_seq = events[-1][0] if events else after_seq
23         return [ev for _, ev in events], last_seq

```

Г.3. Функция потерь Knowledge Distillation

Листинг Г.3: Функция потерь KD для дистилляции SmolVLA

```

1 def distillation_loss(student_actions, teacher_actions,
2                       true_actions, alpha=0.5):
3     min_dim = min(student_actions.shape[-1],
4                   teacher_actions.shape[-1],
5                   true_actions.shape[-1])
6     student_actions = student_actions[..., :min_dim]
7     teacher_actions = teacher_actions[..., :min_dim]
8     true_actions = true_actions[..., :min_dim]
9
10    task_loss = F.mse_loss(student_actions, true_actions)
11    distill_loss = F.mse_loss(student_actions, teacher_actions)
12    return alpha * distill_loss + (1 - alpha) * task_loss

```

ГЛАВА Д. Протоколы экспериментов

Д.1. Протокол тестирования API оркестратора

Контрольная локальная проверка редакции 19.05.2026 выполнялась через `uv` на Python 3.12: `uv run --with pytest --with pytest-asyncio pytest tests/ -q`. Дополнительно задавались `TEST_MODE=true` и `MOCK_LLM=true`. Результат текущего набора: 66 пройдено, 22 провалено, 16 предупреждений. Основные причины падений: тестовые `mock`-объекты не принимают новый аргумент `max_turns`; часть тестов планировщика ожидает старую фиксированную префиксную структуру `Router/RobotInfo`; отдельные проверки LLM-клиента требуют изоляции от реального `OPENAI_API_KEY`.

Д.2. Протокол эксперимента по дистилляции SmolVLA

Среда: Ubuntu 22.04, CUDA 12.1, PyTorch, RTX 4090 (24 ГБ VRAM). Датасет: `lerobot/libero`; в отчёте эксперимента использована валидационная выборка 1200 семплов и 10 эпох стабилизации метрик. Ключевые параметры запуска: `batch_size = 32`, `epochs = 10`, `student_ratio = 0,5`. Параметр `temperature` присутствует в API, но не используется в регрессионной MSE-функции потерь; отдельной λ -компоненты в коде нет.

Д.3. Протокол профилирования инференса

Условия измерения: RTX 4090 (24 ГБ VRAM), CUDA 12.1, `batch_size = 1`, 100 прогонов для усреднения. Метрика: среднее время от подачи тензора до получения выходного вектора действий. Teacher FP32: 450 мс. Student FP16: 18 мс. Ускорение: $25\times$.